

Lab 2 — Attention Mekanizmasının Önemi

microGPT: Attention vs. MLP Karşılaştırması

Ön Bilgi

Bir önceki laboratuvarıda microGPT'nin modüler mimarisini ve temperature parametresini inceledik. Bu laboratuvarıda transformer modellerinin en kritik bileşeni olan self-attention mekanizmasını deneysel olarak sorguluyoruz, onun olmadığı bir modelle karşılaştırıyoruz.

Mimarilerin Tanımı

Orijinal microGPT (microgpt_ablasyon.py — Attention modeli):

Her katmanda Multi-Head Self-Attention + Feed-Forward MLP bloğu bulunur. Attention bloğu, her token'ın tüm önceki tokenlara bakmasını sağlar.

MLP-Only modeli (microgpt_ablasyon.py — MLP-Only modeli):

Attention bloğu, eşit parametrelili 2 katmanlı bir MLP ile değiştirilmiştir. Bu MLP her tokenı yalnızca kendi bilgisiyle işler; önceki tokenlara erişemez.

Parametre Tablosu

Bileşen	Orijinal (Attention)	MLP-Only
Attention ağırlıkları (W_q, W_k, W_v, W_o)	$4 \times (16 \times 16) = 1.024$	—
Attention yerine ctx MLP ($fc1, fc2$)	—	$(16 \times 32) + (32 \times 16) = 1.024$
Feed-forward MLP ($fc1, fc2$)	$(64 \times 16) + (16 \times 64) = 2.048$	$(64 \times 16) + (16 \times 64) = 2.048$
Embedding + LM Head	~1.120	~1.120
TOPLAM	~4.192	~4.192

Temel fark: İki model aynı sayıda parametreye sahiptir. Bu deney, çıktı kalitesindeki farkın ekstra kapasiteden değil, mimarinin yapısından kaynaklandığını kanıtlamak için tasarlanmıştır.

Deney: microgpt_ablasyon.py — Kontrollü Karşılaştırma

Bu laboratuvarıda iki model arasındaki farkı net gözlemleyebilmek için sentetik bir veri seti kullanan microgpt_ablasyon.py scripti kullanılmaktadır. Gerçek isim veri setlerinde attention avantajı kısa diziler ve pozisyon kodlaması nedeniyle maskelenmektedir. Kontrollü deney bunu ortadan kaldırır.

Sentetik Görev Tanımı

Her dizi sabit uzunlukta (7 karakter) oluşturulur:

- Anchor karakterler: 'a' veya 'z' (dizinin ilk ve son karakteri)
- Filler karakterler: alfabe ortası (b–y), rastgele
- Kural: ilk karakter 'a' ise son karakter 'a', 'z' ise 'z'

Dizi	İlk Harf	Kural	Son Harf (hedef)
------	----------	-------	------------------

"abcdfea"	a	a → a	a
"zxmkkpqz"	z	z → z	z
"atocbda"	a	a → a	a

Neden Bu Görev?

Attention modeli: Pozisyon 0'daki anchor'a doğrudan bakabilir — kural trivialdir, kayıp sıfıra yaklaşmalıdır.

MLP-only modeli: Son filler pozisyonunda yalnızca (mevcut_harf, pozisyon) bilgisi vardır. Hangi anchor'un geleceği bilinemez — en iyi ihtimalle ~%50 doğruluk.

Özellik	Attention Modeli	MLP-Only Modeli
Bağlam erişimi	Tüm önceki tokenlar ($Q \times K^T$)	Yalnızca mevcut token
KEY pozisyon tahmini	Pozisyon 0'a bakarak anchor'u bilir	Hangi anchor'un geleceğini bilemez
Beklenen doğruluk	~%100	~%50 (rastgele)

Attention Kafalarının Hesaplanması

Model 4 bağımsız attention kafasına sahiptir. 16 boyutlu vektör 4 kafaya eşit olarak bölünür: her kafa $\text{head_dim} = 16 / 4 = 4$ boyutla çalışır.

Adım 1 — Benzerlik skoru: $\text{pid}=6$ 'daki token, her önceki tokenla nokta çarpımı hesaplar:

$$\text{score}(t) = \sum_j q[j] \times k[t][j] / \sqrt{\text{head_dim}}$$

Adım 2 — Softmax: Skorlar olasılığa dönüştürülür — tüm pozisyonların ağırlıkları toplamı 1'e eşit olur:

$$aw[t] = \exp(\text{score}(t)) / \sum_j \exp(\text{score}(t))$$

Adım 3 — Ağırlıklı toplam: Her pozisyonun V (value) vektörü, attention ağırlığıyla çarpılarak toplanır:

$$\text{out}[j] = \sum_t aw[t] \times v[t][j]$$

Her kafa bu hesabı bağımsız olarak yapar — kendi W_q ve W_k matrislerine sahiptir. Eğitim sırasında her kafa farklı bir örüntüye odaklanmayı öğrenebilir.

Ön Hazırlık

Deneye başlamadan önce aşağıdaki komutu çalıştırın ve çıktıları kaydedin:

```
python microgpt_ablasyon.py
```

Beklenen çıktı yapısı:

- Her 200 adımda kayıp değerleri (attn key_loss ve mlp key_loss)
- Son 500 adım özet tablosu
- 100 yeni örnekte doğruluk testi (prefix + doğru tahmin + model tahminleri)
- 4 örnek için attention ağırlık tablosu (her kafa × her pozisyon)

SORULAR

Soru 1 — Kayıp Değeri Analizi (20 puan)

microgpt_ablasyon.py çıktısından her 200 adımda bir attn key_loss ve mlp key_loss değerlerini aşağıdaki tabloya yazın. Son 500 adım ortalama kayıp değerini de belirtin.

Adım	attn key_loss	mlp key_loss	Fark (+)
200			
400			
600			
800			
1000			
Son 500 adım ort.			

Hangi model daha düşük kayba ulaşmıştır? Bu fark istatistiksel olarak anlamlı mı yoksa rastlantısal mı olabilir? Neden?

Yanıtınız:

Soru 2 — Doğruluk Karşılaştırması (25 puan)

Doğruluk testi çıktısından ilk 10 örneği aşağıdaki tabloya yazın, ardından soruları yanıtlayın.

#	Prefix	Doğru	Attention Tahmini	MLP Tahmini
1				
2				
3				
4				
5				
6				
7				
8				
9				
10				
Toplam doğru			___/100	___/100

a) Attention modelinin ürettiği tahminler nasıldı? Tutarlı bir örüntü gözlemlediniz mi?

Yanıtınız:

b) MLP-only modelinin tahminleri nasıldı? Belirgin bir eğilim var mı?

Yanıtınız:

c) İki model arasındaki en belirgin farkı kendi cümlelerinizle açıklayın.

Yanıtınız:

Soru 3 — Neden Parametre Sayısı Eşit? (20 puan)

microgpt_ablasyon.py dosyasını inceleyin. Attention bloğunun 4 matrisini (W_q , W_k , W_v , W_o) neden tam olarak 2 matrislik bir MLP ile değiştirdiğimizi ve $\text{attn_hidden}=32$ değerinin nasıl seçildiğini matematiksel olarak gösterin.

Yanıtınız:

Soru 4 — Attention Mekanizmasının Temeli (25 puan)

a) Attention bloğu, bir token'ı işlerken kaç önceki token'ın bilgisini kullanır? MLP bloğu kaçını kullanır?

Yanıtınız:

b) Attention mekanizması çıktısını hesaplamak için şu formülü kullanır:

$$\text{Attention}(Q, K, V) = \text{softmax}(Q \times K^T / \sqrt{d_k}) \times V$$

Bu formülde Q , K ve V ne anlama gelir? $\sqrt{d_k}$ ile bölmenin amacı nedir?

Yanıtınız:

c) MLP-only modelin, bir sonraki harfi tahmin ederken neden dezavantajlı olduğunu 3–5 cümleyle açıklayın.

Yanıtınız:

Soru 5 — Deney Tasarımı (10 puan)

Bu deneyin "kontrollü" bir deney olduğunu söyleyebilir miyiz? Parametre sayısını sabit tutmanın bilimsel önemi nedir? Eğer MLP-only modeline daha fazla parametre verilseydi, bu deneyin sonuçlarını nasıl yorumlardınız?

Yanıtınız:

Soru 6 — Attention Kafası Uzmanlaşması (15 puan)

microgpt_ablasyon.py çıktısının attention ağırlık tablosunu inceleyin.

a) 4 kafanın ağırlık değerlerini aşağıdaki tabloya yazın (herhangi bir örnek için — dizi ve anchor'u da belirtin):

Kafa	pid=0 (BOS)	pid=1 (anchor)	pid=2	pid=3	pid=4	pid=5	pid=6
Kafa 1							
Kafa 2							
Kafa 3							
Kafa 4							
Ortalama							

b) Hangi kafa hangi pozisyona odaklanmış? Bu kafanın rolünü açıklayın.

Yanıtınız:

c) Eğitim sırasında bu uzmanlaşma nasıl oluştu? W_q ve W_k matrislerinin rolünü açıklayın.

Yanıtınız:

Toplam: 115 puan | microgpt_ablasyon.py çalışma süresi: ~2–5 dakika | Tüm yanıtları kendi cümlelerinizle yazın.